# ملخّص القسم العملي — كشف تسريب البيانات في التخزين السحابي

غيث جبيلي، بيان عوض، محمد غزال · نسخة مصحّحة · 31 تشرين الأول 2026

## الفكرة بأربعة أسطر

مجموعة البيانات سجلّ لعمليات على تخزين سحابي: 49,500 حدث، كل سطر عملية واحدة، و31% منها مصنّفة تسريبًا. يوضّح كل سطر من قام بالعملية، وكيف سجّل دخوله، وهل جرى الوصول إلى بيانات سرّية أو نقلها، وإلى أين ذهب الملف، وفي أي ساعة.

ندرّب نموذجًا يقرأ سطرًا واحدًا ويجيب عن سؤال واحد: هل هذا الحدث تسريب؟ يُخرج النموذج درجة خطورة بين 0 و1، وتُرفَع الأحداث التي تتجاوز عتبة الإنذار، ويرافق كل إنذار القاعدة التي أنتجته كي يتمكّن المحلّل من مراجعته.

المقال المرجعي (Harahap وHasibuan، 2025) نفّذ ذلك بشجرة قرار واحدة وأعلن دقّة 70.8%. يسأل مشروعنا عمّا إذا كان هذا الرقم يعني شيئًا، وعن عدد التسريبات التي يلتقطها النموذج فعليًا.

## لماذا الدقّة 68.9% فخّ

نموذج يجيب "طبيعي" على كل حدث يحقّق دقّة 68.9% أصلًا، لأن نسبة التسريبات 31% فقط. لذلك لا تستطيع الدقّة وحدها أن تميّز كاشفًا يعمل عن نموذج لا يكشف شيئًا. هذا جوهر نقدنا للمقال، وسبب عرضنا للاستدعاء (Recall) والدقّة الموجبة (Precision) وF1 وMCC إلى جانبها.

الصفوف الثلاثة أدناه مقيسة على مجموعة الاختبار المحجوزة نفسها: 9,900 حدث، منها 3,079 تسريبًا، لم تُستخدم في التدريب إطلاقًا.

| النموذج | الدقّة | الاستدعاء | الدقّة الموجبة | F1 | MCC | نسبة الأحداث المُنذَر عنها |
|---|---|---|---|---|---|---|
| الإجابة "طبيعي" دائمًا | 0.689 | 0.000 | — | 0.000 | 0.000 | 0% |
| شجرة المقال (أعدنا بناءها كما وُصفت) | 0.695 | 0.101 | 0.550 | 0.171 | 0.127 | 6% |
| **شجرتنا بعد الضبط** | **0.696** | **0.827** | **0.507** | **0.628** | **0.429** | **51%** |

اقرأ الجدول عموديًا. على مقياس الدقّة تبدو النماذج الثلاثة متطابقة تقريبًا (0.689 و0.695 و0.696)، أي أن نموذج المقال يتفوّق على التخمين بـ 0.6 نقطة فقط. أما على الاستدعاء فالفرق كبير: شجرة المقال تجد 311 تسريبًا من أصل 3,079، وشجرتنا تجد 2,547، أي نحو **8 أضعاف**. ويرتفع MCC، الذي يستعمل خانات مصفوفة الالتباس الأربع ويساوي صفرًا عند التخمين، من 0.127 إلى 0.429.

> **ملاحظة عن الترميز.** يذكر المقال أنه استخدم ترميز one-hot، فأعدنا بناء شجرته كذلك، وهي المرجع في الجدول. لكن شجرته المنشورة تقسم على الشرط `Authority ≤ 3.5`، وهذا لا يكون إلا إذا حُرّنت الأدوار أرقامًا. بهذه القراءة تبلغ دقّتها 0.701 واستدعاؤها 0.298، وهو قريب من الرقمين المنشورين (0.708 و0.315)، وتلتقط 918 تسريبًا؛ وحتى مقارنةً بها تلتقط شجرتنا نحو 2.8 ضعف.

## الثمن

الثمن ظاهر في العمود الأخير: ننذر عن 51% من الأحداث بدل 6%، وواحد من كل إنذارين تقريبًا تسريب حقيقي (0.507 مقابل 0.550). هذه المقايضة مقصودة، لأن تسريبًا فائتًا أغلى من إنذار كاذب في هذا السياق، وهي محكومة بعتبة الإنذار القابلة للتعديل: عند هدف استدعاء 0.7 مثلًا ينخفض عدد الإنذارات إلى 379 لكل 1,000 حدث بدل 490.

## لماذا قارنّا ثلاث خوارزميات

لم نختر النموذج بالذوق. أخذنا ممثّلًا عن كل عائلة من العائلات الثلاث التي تناسب البيانات الجدولية، ودرّبناها في ظروف متطابقة، وقارنّاها بمساحة منحني الدقّة-الاستدعاء (PR-AUC) لصنف التسريب، وهو المقياس الذي يقيس المفاضلة بين الدقّة الموجبة والاستدعاء بدل مكافأة الإجابة "طبيعي".

| الخوارزمية | لماذا اخترناها | ماذا وجدنا |
|---|---|---|
| شجرة قرار مفردة | نموذج المقال نفسه، والوحيد الذي ينتج قواعد IF-THEN يقرؤها المحلّل | **اعتُمدت** (PR-AUC 0.622). ضبط العمق وحجم الورقة وأوزان الأصناف يرفعها كثيرًا فوق نسخة المقال ذات العمق 3 |
| الغابة العشوائية (Bagging) | أشجار كثيرة على عيّنات عشوائية، وهي المعالجة المعيارية حين تكون الشجرة الواحدة غير مستقرّة | جُرّبت ولم تُعتمد (0.633): لا قواعد مقروءة، ولا أفضلية على XGBoost |
| XGBoost (Boosting) | عادةً أقوى نموذج على البيانات الجدولية، ويصلح حدًّا أعلى صادقًا للمقارنة | أفضل نتيجة (0.634)، لكن بفارق 0.013 فقط عن الشجرة، وهو أقل من أن نضحّي بالقابلية للتفسير |

هذه المقارنة هي ما يبرّر اختيارنا النهائي: نستطيع القول إن النموذج القابل للتفسير يكلّفنا 0.013 من PR-AUC، بدل الادّعاء أن الشجرة "كافية" بلا دليل.

وأجرينا المقارنة نفسها لمعالجة عدم التوازن، لأن التسريبات هي الصنف الأقلّي. تفوّقت أوزان الأصناف (تجعل حدث التسريب يُحسَب نحو 2.2 ضعف الحدث الطبيعي أثناء التدريب) على التوليد الاصطناعي SMOTEN وعلى زيادة العيّنات وإنقاصها عشوائيًا. فتوليد أحداث تسريب اصطناعية لا يفيد هنا، لأن أحداثًا متطابقة تحمل الصنفين معًا، ولا تستطيع النسخ الإضافية الفصل بينها.

## ماذا بنينا (القسم العملي)

القسم العملي دفتر Jupyter واحد، `leakage_detection.ipynb`، مقسّم إلى 11 خطوة تعمل بالترتيب من الأعلى إلى الأسفل على Google Colab أو على الجهاز. يحفظ الدفتر كل الجداول والأشكال في المجلد `results/`، والنموذج النهائي مع عتبته في `models/final_tree.joblib`، والكود كله منشور في مستودع المشروع على GitHub.

| الخطوات | وظيفتها |
|---|---|
| 1. تحميل البيانات | يقرأ ملف CSV ويشتقّ الساعة من عمود التاريخ بصيغتيه. لا تدريب هنا |
| 2. تدقيق البيانات | نسبة الأصناف، القيم الناقصة، نسبة التسريب حسب الساعة |
| 3. السقف | يقيس أعلى دقّة يمكن لأي نموذج بلوغها بهذه السمات، قبل أن ندرّب أي شيء |
| 4. التقسيم وشجرة المقال | يقسم البيانات 80:20 ويحجز مجموعة الاختبار، ثم يعيد بناء شجرة المقال على التقسيم نفسه كي يُقاس كل تحسّن مقابل مرجع حقيقي |
| 5–8. الضبط والمقارنات والعتبة | ضبط الشجرة، إضافة السمتين، مقارنة النماذج وطرق الموازنة، اختيار عتبة الإنذار |
| 9. الاختبار النهائي | تقييم واحد على مجموعة الاختبار المحجوزة |
| 10–11. التفسير والحفظ | قواعد IF-THEN وأهمية السمات، ثم حفظ النموذج والعتبة |

أما الخدمة التي تحسب درجة حدث وارد وتعيد الدرجة والتصنيف والقاعدة (النموذج الأولي) فلم تُبنَ بعد، وهي من الخطوات القادمة مع اختبار التهرّب.

ثمّة نتيجة من خطوة السقف تستحقّ الذكر وحدها: بسمات المقال التسع، 91% من الأحداث مطابقة لأحداث تحمل الصنف المعاكس، أي أنه لا يستطيع أي نموذج تجاوز نحو 74% دقّة عليها. الحدّ في البيانات لا في الخوارزمية. ولهذا أضفنا سمتين أهملهما المقال، هما وجهة الملف (داخلية أم خارجية) وساعة الحدث، وتضيفان معًا 0.122 إلى PR-AUC، أي أكثر بكثير من أي تغيير في النموذج.

## خطّ المعالجة (Pipeline) ولماذا ترتيبه مهم

خطّ المعالجة كائن واحد يسلسل كل الخطوات التي يحتاجها النموذج، فتُدرَّب السلسلة وتُطبَّق كوحدة واحدة. ويتألّف خطّ النموذج النهائي من ثلاث خطوات بهذا الترتيب:

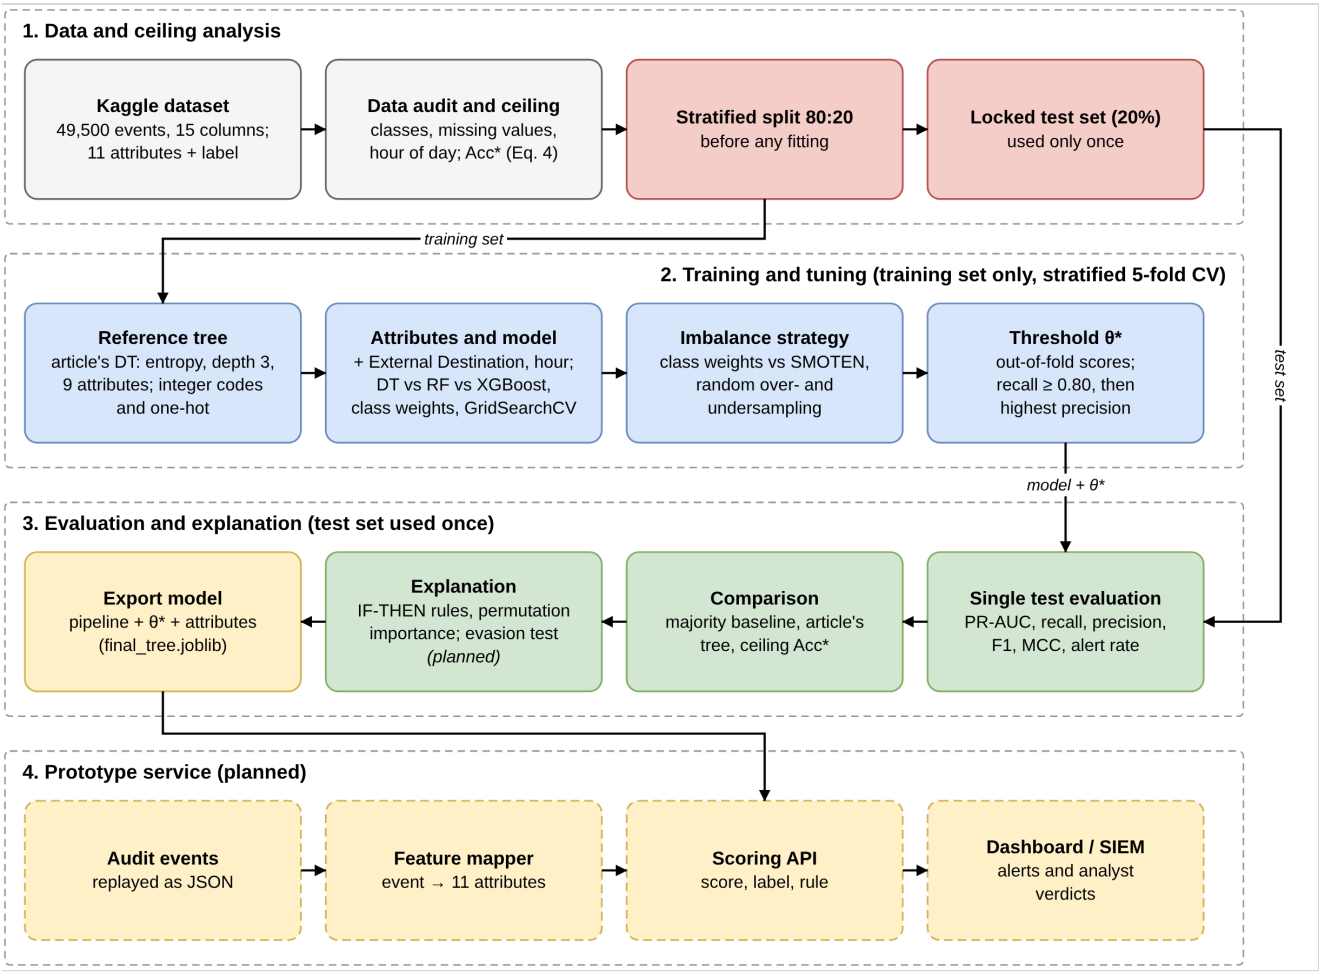
1. **التعويض (Impute)** — ملء القيم الناقصة (نحو 10% من الأسطر فيها قيمة ناقصة) بالقيمة الأكثر تكرارًا، وبالوسيط للساعة.
2. **الترميز (Encode)** — تحويل الدور ونوع العملية وبقية الفئات إلى أعمدة 0/1 يستطيع النموذج استعمالها.
3. **النموذج (Model)** — شجرة القرار نفسها. أوزان الأصناف إعداد داخل الشجرة وليست خطوة مستقلة.

وعند تجربة طرق إعادة العيّنات (SMOTEN والزيادة والإنقاص العشوائيّان) أُضيفت خطوة رابعة بين التعويض والترميز. والترتيب هنا ليس شكليًا: تأتي إعادة العيّنات بعد التعويض لأنها لا تعمل مع قيم ناقصة، وقبل الترميز كي تعمل على الفئات الأصلية.

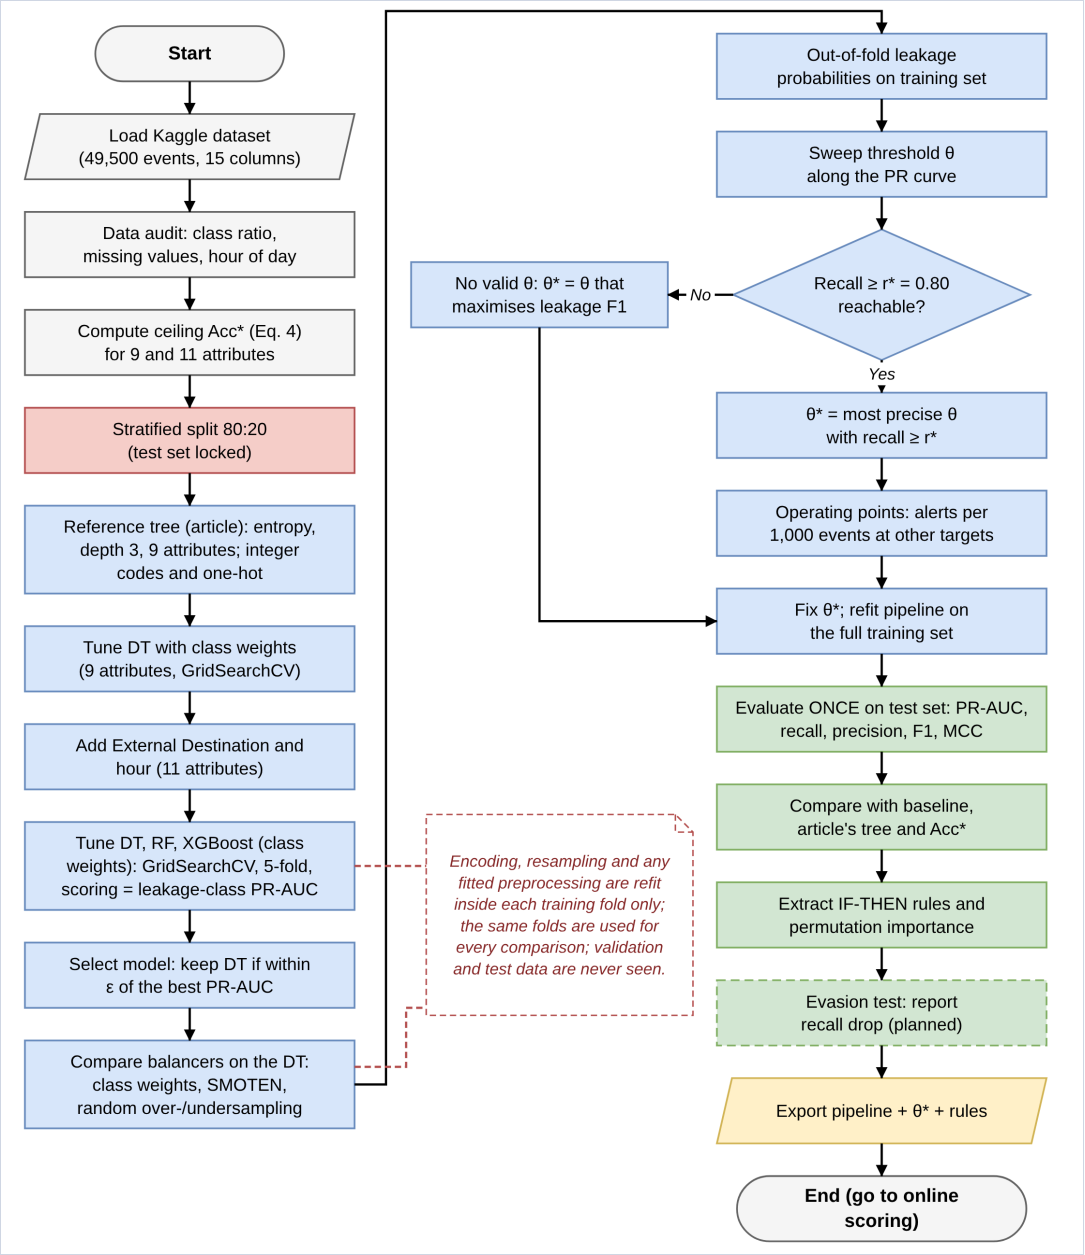
أما سبب استعمال خطّ معالجة أصلًا فهو الخطأ الذي ننتقده. إذا عوّضت القيم الناقصة أو ولّدت عيّنات على كامل البيانات ثم قسّمت بعد ذلك، تكون معلومات أسطر الاختبار قد دخلت التدريب، وتصبح النتيجة المعلنة أعلى من الحقيقة. وداخل خطّ المعالجة تُعاد تهيئة كل خطوة من الصفر على طيّات التدريب فقط، فتبقى أسطر التحقّق والاختبار سليمة. لا يذكر المقال أنه فعل ذلك، بينما يفعله مشروعنا بحكم البناء.

## قراءة المخطّطات

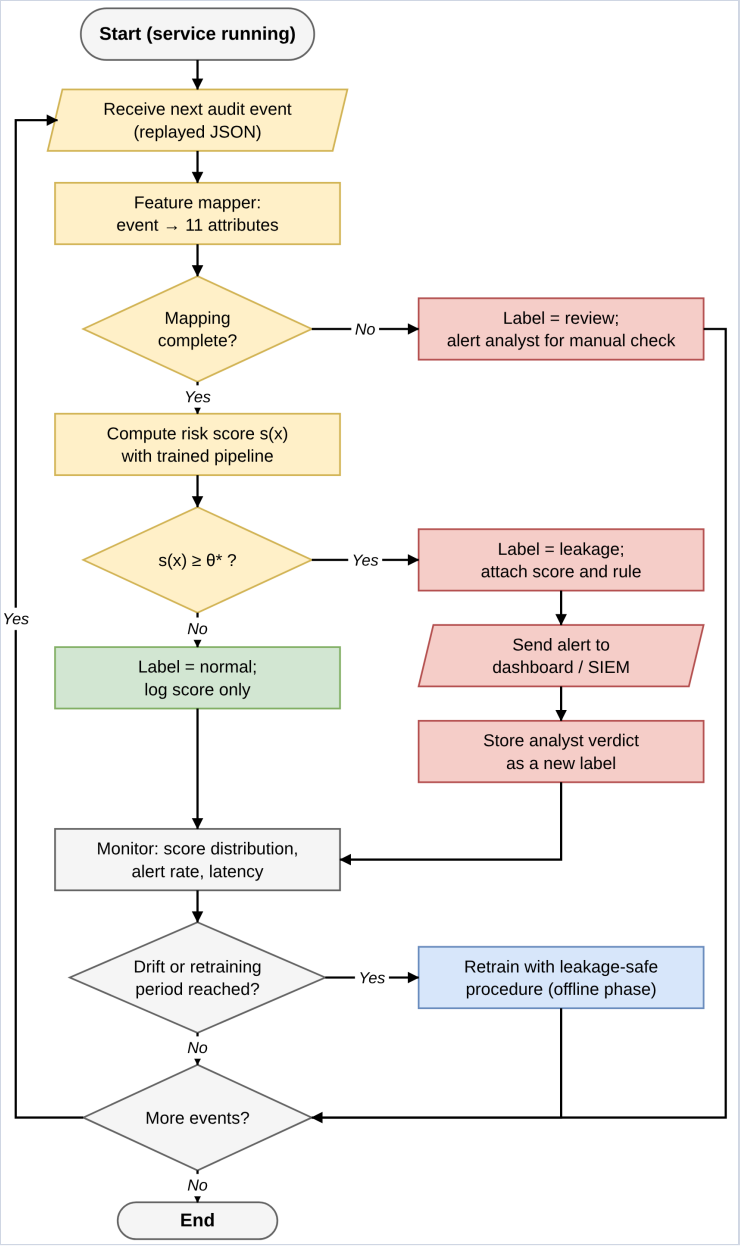
يحمل الفصل الثاني من التقرير ثلاثة أشكال لهذا الغرض. الشكل 12 هو المخطّط الصندوقي للحلّ كاملًا، والشكلان 13 و14 هما المخطّطان الانسيابيان، ووجودهما لأن النظام يعمل في طورين منفصلين. الصناديق ذات الإطار المتقطّع مخطّطة ولم تُنفَّذ بعد.




**الشكل 12 — المخطّط الصندوقي للحلّ.** رمادي: تحليل البيانات والسقف؛ أحمر: التقسيم؛ أزرق: خطوات تُدرَّب على بيانات التدريب وحدها؛ أخضر: الاختبار الوحيد؛ أصفر: حفظ النموذج والخدمة؛ متقطّع: مخطّط.




**الشكل 13 — الطور غير المباشر: كيف يُبنى النموذج.** يُقرأ العمود الأيسر من الأعلى إلى الأسفل ثم الأيمن. تُدقَّق البيانات ويُحسَب السقف، ثم تُقسَم 80:20 وتُحجَز مجموعة الاختبار. بعدها تُنفَّذ تجارب التدريب بترتيب الدفتر نفسه وبتحقّق متقاطع خماسي على بيانات التدريب وحدها: شجرة المقال، ضبط الشجرة، إضافة السمتين، مقارنة النماذج الثلاثة (تُفصَّل الشجرة إن كانت ضمن هامش ε من الأفضل)، ثم مقارنة طرق الموازنة. وتُختار عتبة الإنذار من درجات خارج الطيّات، والمعيّن في العمود الأيمن هو قرار العتبة: هل يمكن بلوغ استدعاء 0.80؟ إن نعم تُختار أدقّ عتبة تحقّقه، وإلا العتبة التي تعظّم F1. ثم يُعاد تدريب النموذج على كامل بيانات التدريب، وعندها فقط تُفتَح مجموعة الاختبار مرّة واحدة.




**الشكل 14 — الطور المباشر: كيف يُقيَّم حدث واحد (النموذج الأولي المخطّط).** يُقرأ كحياة حدث تدقيق مفرد. يصل الحدث، فيحوّله مُسقِط السمات إلى السمات الإحدى عشرة، ويسأل المعيّن الأول إن كان التحويل كاملًا: فإن لم يكن، يُصنَّف الحدث للمراجعة ويُحال إلى محلّل بدل أن يُعدّ طبيعيًا بصمت. وإلا فيُنتج خطّ المعالجة درجة خطورة، ويقارنها المعيّن الثاني بالعتبة، فيصبح الحدث إمّا إنذارًا يحمل قاعدته وإمّا حدثًا طبيعيًا مسجَّلًا. وتعود الحلقة في الأسفل إلى الطور غير المباشر: عند انحراف البيانات يُعاد تدريب النموذج.

إذًا يُنفَّذ الشكل 13 مرّة واحدة في الدفتر وينتج ملف النموذج، بينما سيُنفَّذ الشكل 14 لكل حدث داخل الخدمة مستعملًا ذلك الملف.